Taller 06 — Generación de texto y traducción seq2seq

Procesamiento de Lenguaje Natural · Pontificia Universidad Javeriana

David Moreno · Dierick Brochero

Código: https://github.com/davidm094/NLP_JAVE_TALLER06_202601

Resumen

Se adaptó el notebook de clase (*Deep Learning with Python*, 3a ed., cap. 15) a dos tareas. (1) Un modelo de lenguaje por caracteres (GRU) entrenado con *Rebelión en la granja* de George Orwell llega a una perplejidad de validación de **4,16** por carácter y genera texto con la puntuación, los personajes y el tono de la novela, pero sin coherencia más allá de unas pocas palabras; con temperaturas bajas, buena parte de lo que "acierta" es copia literal del libro. (2) Un seq2seq GRU español→inglés entrenado con 9.758 pares cortos de *Combined Data es-ES* obtiene en test **BLEU 3,32**, **ROUGE-1 21,9**, **ROUGE-L 21,1** y **F1 21,8**. Duplica a la línea base de copiar el español en ROUGE-1, ROUGE-L y F1, pero no la supera en BLEU: el modelo aprende vocabulario frecuente del inglés, no a conservar el significado de la frase.

Arquitectura de la solución

La solución tiene dos pipelines independientes que comparten la misma organización de código (Figura 1): los datos entran por `src/`, cada etapa guarda lo que produce en `results/` (modelos, historias de entrenamiento, muestras, traducciones y métricas), y el reporte, las figuras y el notebook se generan leyendo solo de `results/`. Así ninguna cifra del reporte se copia a mano. La Figura 2 muestra las dos redes con sus dimensiones.

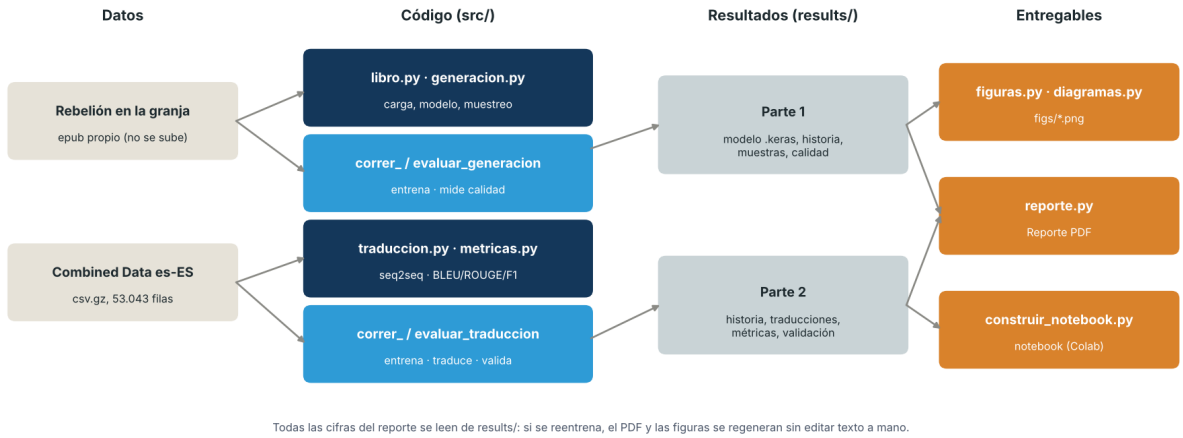


Figura 1. Arquitectura del código: datos, módulos de src/, resultados y entregables.

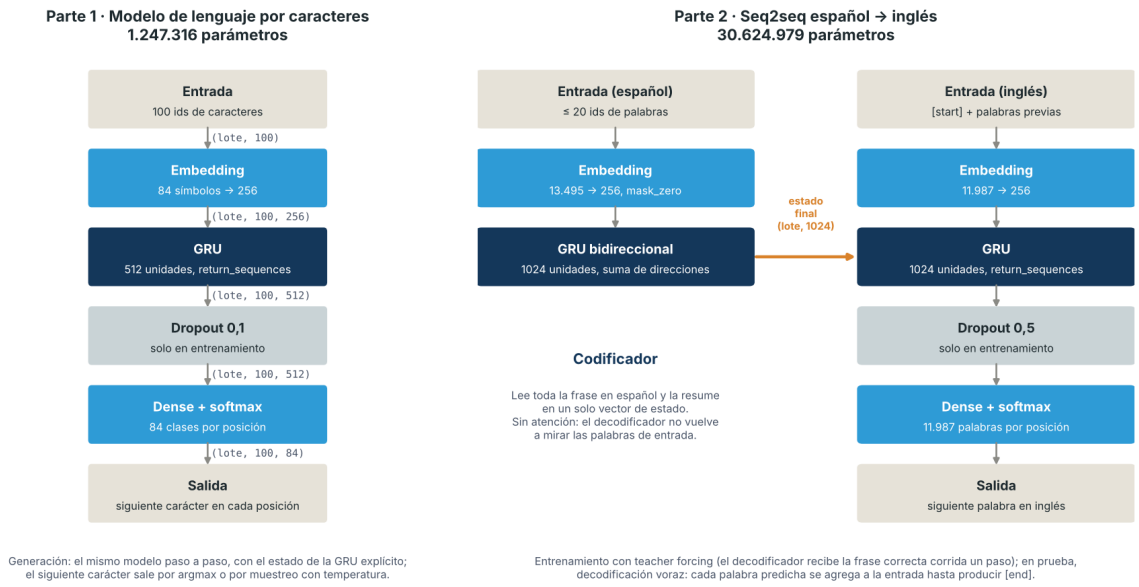


Figura 2. Arquitectura de los modelos. Izquierda: modelo de lenguaje por caracteres (formas de los tensores en las flechas). Derecha: seq2seq; el estado final del codificador (flecha naranja) es el estado inicial de la GRU del decodificador.

1. Generación de texto con un libro

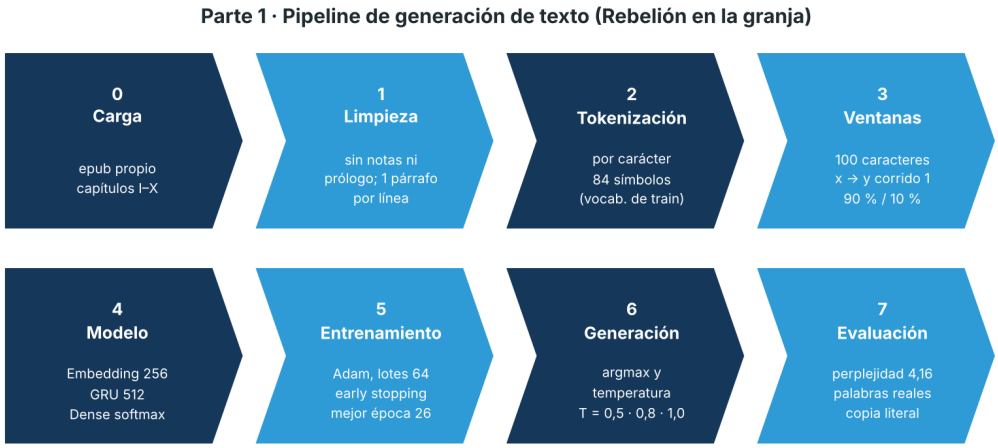


Figura 3. Pipeline de la Parte 1, de la carga del libro a la evaluación del texto generado.

1.1 Libro y preparación

Libro: *Rebelión en la granja* (*Animal Farm*, George Orwell, 1945), en la traducción al español de Marcial Souto. Es un libro que leímos ambos integrantes del grupo. La obra **no es de dominio público en Colombia**: Orwell murió en 1950 y aquí la protección dura la vida del autor más 80 años, hasta el 1 de enero de 2031. Se usa solo para entrenar el modelo en esta actividad académica sin fines comerciales, y por eso el texto **no está en el repositorio**: el código lo lee de una copia propia en epub (`data/Rebelion_en_la_granja.epub`, excluida en `.gitignore`).

Del epub se toman solo los diez capítulos de la novela (I a X): quedan fuera la portada, los créditos, el prólogo de Orwell (*La libertad de prensa*), el epílogo y las notas, que no son parte del relato. Se quitan las llamadas a notas y queda un párrafo por línea. Resultado: **171.088** caracteres y un vocabulario de **84** símbolos (incluye relleno y [UNK]). Es un corpus pequeño: unas 6,5 veces menos texto que el de Shakespeare del notebook.

Como en el notebook, se cortan ventanas no solapadas de 100 caracteres y la etiqueta es la misma ventana corrida un carácter. **Cambio frente al notebook:** el último 10 % del libro queda como validación (172 ventanas; 1.540 de entrenamiento) para medir el modelo en texto no visto y detener el entrenamiento con *early stopping* (paciencia 3, se restauran los mejores pesos).

1.2 Modelo

Embedding de 256 → GRU con `return_sequences` → Dropout 0,1 → Dense softmax sobre los 84 símbolos; Adam y entropía cruzada. El notebook usa una GRU de 1024 unidades; aquí se entrenó con **512** para que corriera en CPU (no había GPU disponible). No parece ser lo que limita al modelo: con solo 1.540 ventanas de entrenamiento, la red de 512 ya sobreajusta (Figura 4), así que más unidades difícilmente ayudarían sin más texto. El notebook mantiene 512 para reproducir este reporte; cambiar a 1024 es una línea (`GEN_OCULTO`).

1.3 Resultados del entrenamiento

Métrica	Entrenamiento (mejor época)	Validación (mejor época)
Pérdida (nats por carácter)	1,099	1,425
Perplejidad por carácter	3,00	4,16
Exactitud del siguiente carácter	0,659	0,584

La exactitud de entrenamiento es el promedio de la época con dropout activo; la de validación, sin dropout: no son estrictamente comparables.

El entrenamiento corrió 29 épocas (8,6 min); la mejor validación fue en la época 26. Una perplejidad de 4,16 significa que, en promedio, el modelo duda entre unos 4,2 caracteres igual de probables en cada paso (de 84 posibles).

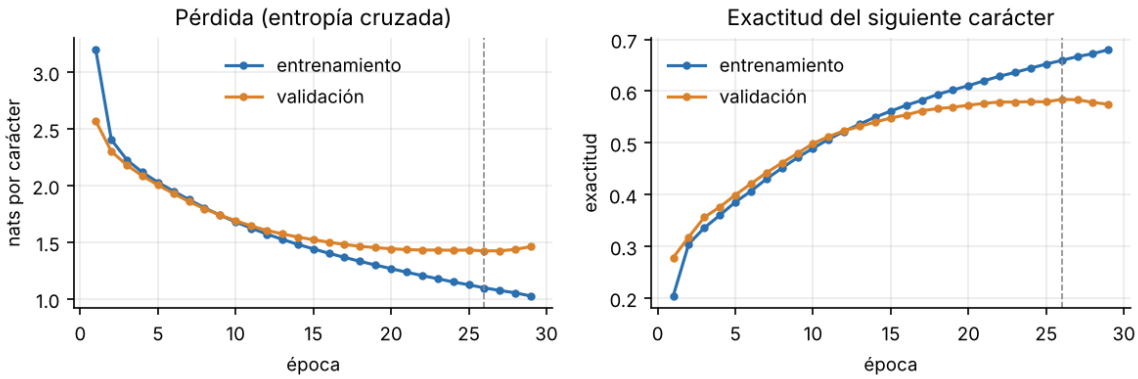


Figura 4. Curvas de entrenamiento del modelo de caracteres. La línea punteada marca la época con menor pérdida de validación, cuyos pesos se conservan.

1.4 Texto generado

El notebook genera con **argmax** (siempre el carácter más probable). Se comparó con **muestreo con temperatura** *T*: se divide el logaritmo de las probabilidades por *T* y se renormaliza. Muestras de 350 caracteres (semilla fija):

Prompt «Napoleón» · argmax (notebook)

```
Napoleón era un cerdo de la casa de la casa de la casa de la casa de la casa de la casa de la casa de
la casa y los animales de la casa y los animales de la casa y los animales de la casa y los animales
de la casa y los animales de la casa y los animales de la casa y los animales de la casa y los
animales de la casa y los animales de la casa y los animales
```

Prompt «Napoleón» · T = 0,5

```
Napoleón y el abueran en la casa de la casa de la cosecha de la granja, pero el propio se les otra
cantar a medida que cabalante de la casa reunidad en la cabaza, y en el aumento con el que causa todo
el daño.
Las aves no entendieron las palabras que se opio animal de manera de la casa. Se le actuaba como si
los animales de la contenciando con sus probutio
```

Prompt «Napoleón» · T = 1,0

```
Napoleón, pero por su cezdió al actutido a la habían camadadada y Trébol, labatamente, entrendera al
capal de la calabra Napoleón, lo les voldó Jones, y que y había reseguado detende sus expulsanes era
el lugor de mucho atrepentirado dentro pasa de sus ordenes de actender aunque nunca hubiera situado
cómo si una leete dentir tón vuestra los arecar mueztros
```

Prompt «—¡Camaradas» · argmax (notebook)

```
—¡Camaradas —dijo—, los animales se dispersaban.
El tercer domingo después de la casa de la casa de la casa de la casa de la casa de la casa de la casa
de la casa de la casa de la casa de la casa de la casa de la casa de la casa de la casa de la casa de
la casa y los animales de la casa y los animales de la casa y los animales de la casa y los animales
de la
```

Prompt «—¡Camaradas» · T = 0,5

```
—¡Camaradas —dijo—, la reunión de esta vez a la casa y los animales de la casa de la tarea. La «¡No
tenía una egada lograr la primera es de acto. Estaba en los otros agriciones a la matanza sobre todo
lo que estaba al primera tenía una certeza de haber visto que tenía la paredía a carrar de altadas de
la granja de la granja y se sentaba a cantar la cansada en
```

Prompt «—¡Camaradas» · T = 1,0

```
—¡Camaradas Morcera de repente hacia el trabajo contrá lado de lo que se les había indenedo en
finalentes. Sin deba debe de comité iba a la mucho a los otros.
Una manexaliente y creaina, y camaradas, cuatro hacerse al puertad de los tiempos por dal año sus
decía que el hombre Un rebelidad, del año anterinte que solo lo era los animales la parte para
realidad.
```

Para no juzgar solo a ojo, se generaron 500 caracteres por estrategia con los tres prompts (dos semillas cuando hay muestreo) y se midió: qué porcentaje de las palabras generadas existe en el libro, qué fracción de los bigramas de palabras es distinta (1 = no se repite nada), qué porcentaje de los 5-gramas de palabras generados aparece tal cual en el libro (copia literal) y el tramo más largo de palabras seguidas copiado del libro:

Estrategia	Palabras generadas	% palabras que existen en el libro	Bigramas distintos / total	% 5-gramas copiados del libro	Tramo copiado más largo
argmax (notebook)	355	99,4	0,11	25,4	10 palabras
T = 0,5	590	93,9	0,85	15,5	13 palabras
T = 0,8	563	82,9	0,94	0,6	5 palabras
T = 1,0	539	70,7	0,97	0,8	7 palabras

1.5 Análisis

- **Argmax entra en ciclos.** Siempre elige el carácter más probable y termina repitiendo «de la casa y los animales de la casa…»: el 99,4 % de las palabras son reales, pero solo el 11 % de los bigramas es distinto. Su 25 % de 5-gramas «copiados» sale casi todo de dos 5-gramas (*de la casa y los*, *la casa y los animales*) que el ciclo repite entre 10 y 16 veces por prompt (81 de los 87 5-gramas copiados): no es memoria de pasajes. Es lo que daría el notebook de clase tal como está.
- **Con T = 0,5 el texto se ve mejor en parte porque recita el libro.** El 15,5 % de sus 5-gramas está literal en la novela y llega a copiar 13 palabras seguidas. Un ejemplo de las muestras: «haber visto que te hablaba y que tú te dejabas acariciar» (11 palabras), que en el libro aparece una sola vez. Con un corpus tan corto, una distribución concentrada lleva al modelo a los caminos que vio en entrenamiento.
- **Con T ≥ 0,8 deja de copiar pero inventa.** La copia literal baja a 0,6 % (T = 0,8) y 0,8 % (T = 1,0), pero las palabras que existen bajan a 83 % y 71 % (*camadadada*, *lugor*, *cezdíó*). No hay una temperatura que dé a la vez variedad, palabras reales y texto propio: es el límite de un modelo de caracteres entrenado con ~154 mil caracteres.
- **Qué aprendió.** La forma del texto: el diálogo con raya («—¡Camaradas —dijo—, …»), las comillas latinas, la puntuación española (¡…!, ¿…?), concordancias cortas y el universo de la novela: *Napoleón*, *Bola de Nieve*, *Boxeador*, *Trébol*, *Jones*, *la Granja Animal*, *el molino de viento*.
- **Qué no aprendió.** No hay coherencia más allá de unas pocas palabras y el texto no sigue al prompt: tras unas decenas de caracteres, las muestras de prompts distintos hablan de lo mismo (la casa, los animales, la granja). Por eso cada prompt usa su propia semilla: con la misma secuencia de números aleatorios, dos muestras pueden terminar idénticas.
- **Sobreajuste.** Las curvas se separan desde la época ~12; la validación toca fondo en la época 26 (1,425) mientras el entrenamiento sigue bajando (1,027 en la época 29). Con ~154 mil caracteres de entrenamiento la red de 512 unidades tiene capacidad para memorizar; más texto (otras obras de Orwell) o una red más pequeña con más dropout serían el siguiente paso.

2. Traducción español → inglés con seq2seq

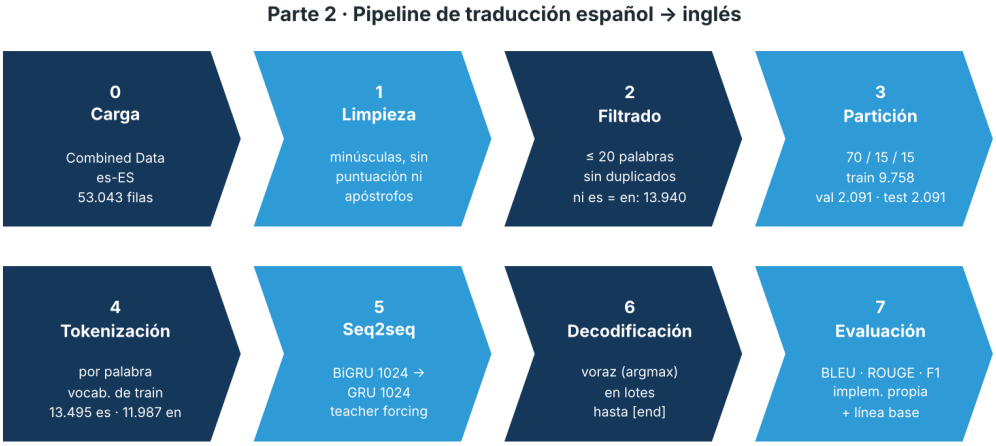


Figura 5. Pipeline de la Parte 2, de la carga del dataset a la evaluación con BLEU, ROUGE y F1.

2.1 Datos

Combined Data es-ES trae 53.043 textos de salud mental (Reddit/Twitter) con el original en inglés (`statement`) y su traducción al español (`statement_es_es`), así que sirve como corpus paralelo. La fuente es el español y el destino el inglés, con `[start]` y `[end]`, al revés del notebook (inglés→español).

Paso	Pares que quedan	Motivo
Filas del archivo	53.043	
Con texto en ambos idiomas	52.671	se quitan vacíos
≤ 20 palabras (es) y ≤ 19 (en)	15.045	un seq2seq sin atención resume toda la frase en un vector; la mediana del dataset es de 53 palabras en español y 62 en inglés. 19 en inglés para que [start] + 19 + [end] quepan en las 21 posiciones del notebook
Sin pares duplicados	14.772	
Sin pares idénticos es = en	13.940	no están traducidos (hashes, risas, otros idiomas, inglés sin traducir); enseñarían a copiar e inflarían las métricas

Normalización: minúsculas, sin puntuación ni ¿¡ y sin apóstrofo (*don't* → *dont*). Partición aleatoria 70/15/15 con semilla 42: **9.758** de entrenamiento, **2.091** de validación y **2.091** de prueba. Vocabularios (de entrenamiento, incluidos los tokens especiales): 13.495 en español y 11.987 en inglés; el 9,7 % de las palabras en español del test no aparece en entrenamiento.

2.2 Modelo

Arquitectura del notebook: embedding 256 → GRU bidireccional de 1024 unidades (suma de direcciones) como codificador; su estado final inicializa la GRU del decodificador, que recibe la frase en inglés corrida un paso (*teacher forcing*) → Dropout 0,5 → Dense softmax. La pérdida ignora el relleno (*sample weights*). **Único cambio de arquitectura:** `mask_zero=True` en el embedding del codificador; sin máscara, la dirección hacia atrás de la GRU bidireccional empieza leyendo los ceros de relleno.

Se entrenó con Adam, lotes de 64 y *early stopping* sobre la pérdida de validación (paciencia 3). Paró en la época 7 y conservó la 4 (pérdida de validación 2,776, exactitud por palabra 0,266); 30,9 min en CPU. Desde la época 5 la pérdida de entrenamiento sigue bajando y la de validación sube: sobreajuste temprano por la poca cantidad de datos.

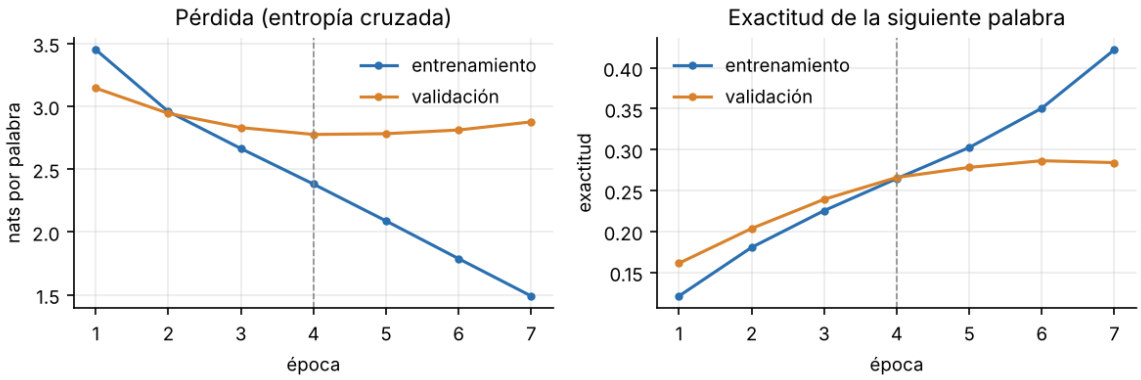


Figura 6. Curvas del seq2seq. La línea punteada marca la época conservada.

2.3 Métricas implementadas

Las tres métricas están implementadas desde cero en `src/metricas.py` y se validan contra las librerías estándar (`sacrebleu` y `rouge-score`).

- **BLEU** (Papineni et al., 2002), a nivel de corpus. Para n = 1…4 se cuentan los n-gramas de cada predicción y se recortan al número de veces que aparecen en su referencia (así repetir una palabra correcta no suma de más); p_n = coincidencias / n-gramas predichos, sumando sobre todo el test. Penalización de brevedad: BP = exp(1 − r/c) si la longitud total de las predicciones (c) es menor que la de las referencias (r), si no 1. BLEU = BP · exp(¼ Σ log p_n). Es exigente: sin 4-gramas correctos el puntaje cae aunque haya palabras sueltas bien.
- **ROUGE-N** (Lin, 2004): con los n-gramas compartidos (recortados), precisión = compartidos / n-gramas de la predicción, recall = compartidos / n-gramas de la referencia y F = 2PR/(P+R). Se usa N = 1 y 2. **ROUGE-L**: igual, pero con la longitud de la subsecuencia común más larga (LCS, por programación dinámica). Por frase y promediadas.
- **F1 por palabras** (inspirado en el F1 de SQuAD, sin quitar artículos): precisión = palabras de la predicción que están en la referencia (contando repeticiones); recall = palabras de la referencia que aparecen en la predicción; F1 = media armónica. Por frase y promediado. Es casi ROUGE-1 desde otro tokenizador: F1 usa las palabras tal cual (con ñ y tildes) y ROUGE solo a–z y 0–9, igual que rouge-score. Se interpretó «F1-score» como esta medida por palabras, la usual en generación de texto, y no como una combinación de BLEU y ROUGE.

Todas se calculan sobre texto normalizado (minúsculas, sin puntuación), que es la forma en que el modelo produce el inglés. La traducción del test se hace con decodificación voraz, el mismo algoritmo de `generate_translation` del notebook, pero en lotes. Como **línea base** se usa copiar la frase en español sin cambios.

Validación. Sobre las 2.091 predicciones del test:

Métrica	Propia	Librería	Diferencia
BLEU de corpus	3,3173	3,3173 (sacrebleu, tokenize='none')	0,0000
ROUGE-1 promedio	21,8813	21,8813 (rouge-score)	0,0000; máx. por frase 0,0000
ROUGE-2 promedio	5,7285	5,7285 (rouge-score)	0,0000; máx. por frase 0,0000
ROUGE-L promedio	21,0650	21,0650 (rouge-score)	0,0000; máx. por frase 0,0000

El BLEU propio toma como tokens las palabras separadas por espacio. El tokenizador por defecto de sacrebleu (13a) separa además algunos símbolos que quedaron en el texto y da 3,31; la diferencia no cambia ninguna conclusión.

2.4 Resultados en test

Sistema	BLEU	ROUGE-1	ROUGE-2	ROUGE-L	F1	Precisión	Recall
seq2seq GRU	3,32	21,9	5,7	21,1	21,8	23,3	21,4
Línea base: copiar el español	3,47	10,2	3,2	10,1	10,5	10,6	10,6

Detalle de BLEU del modelo: `BLEU = 3.32 | precisiones 1-4: 21.9/5.2/1.8/0.7 | BP = 0.955`. De la línea base: `BLEU = 3.47 | precisiones 1-4: 10.9/4.0/2.3/1.5 | BP = 0.985`. Escala 0–100 en todas.

Longitud (palabras en español)	Frases	BLEU	ROUGE-1	ROUGE-2	ROUGE-L	F1
1-5	564	6,44	23,1	7,4	22,9	23,1
6-10	768	4,58	23,4	6,8	22,7	23,3
11-15	489	2,47	19,9	3,7	18,8	19,8
16-20	270	1,73	18,5	2,9	16,6	18,4

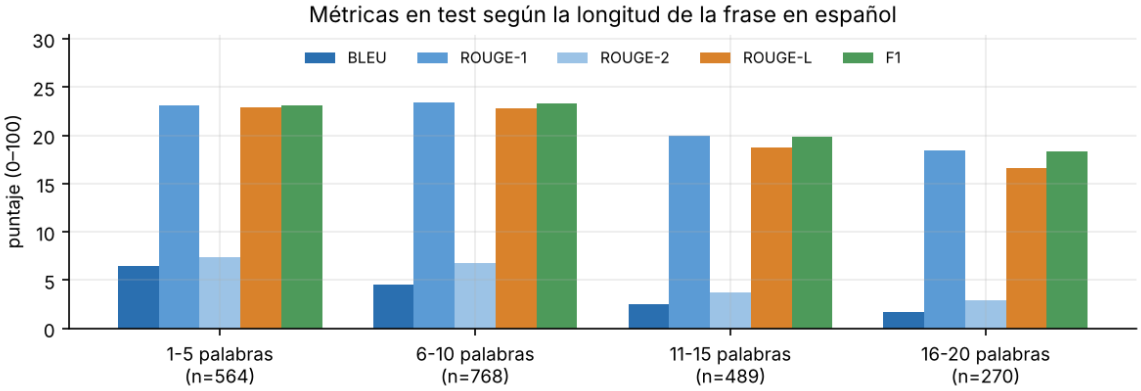


Figura 7. Métricas en test por tramo de longitud de la frase en español.

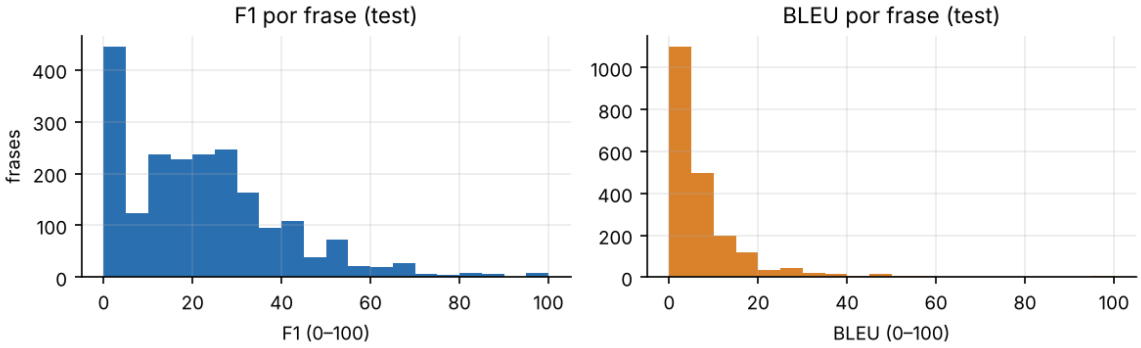


Figura 8. Distribución de F1 y BLEU por frase en el test. El BLEU por frase de esta figura lo calcula sacrebleu.sentence_bleu con suavizado (sin suavizado casi todas las frases darían 0); las cifras de BLEU de las tablas son de corpus, con la implementación propia.

2.5 Ejemplos del test

Ejemplos elegidos para cubrir aciertos, aciertos parciales y fallos (F1 por frase, 0–100). Se evitaron textos con contenido sensible del dataset; todas las predicciones están en `results/traducciones_test.csv`.

Español (entrada)	Referencia (inglés)	Predicción del modelo	F1
no me gusta que la recalienten	i dont like it reheated	i dont like it	89
tengo que ir al baño	i have to go to the bathroom	i have to go to the bank	86
este es un buen barrio	this is a great neighborhood	this is a great game	80
no puedo creer que ganó las elecciones	i cant believe he won the election	i cant believe it	55
bueno no olvides esto bro	well dont forget this bro	well i dont know that	40
y qué más debería hacer	what else should i do	what do you do you	40
te gustaría ver una película conmigo y mi amigo	would you like to see a movie with me and my friend	do you want to be a little day	30
supongo que realmente le gustaba su nueva novia	i guess he really liked his new girlfriend	i think i have to the beach	13
un coche que ha sido propiedad de una anciana	a car that was owned by a little old lady	a little little a little good	37

2.6 Análisis

- **El modelo aprende el inglés frecuente, no la traducción.** La mediana de F1 por frase es 20 (cuartiles 8–31) y el 21 % de las frases no comparte ninguna palabra con la referencia. Las frases cortas con estructuras comunes (*i dont like…*, *i have to go…*) salen bien; en el resto el decodificador arranca bien y luego sigue con una continuación frecuente en inglés (*bathroom* → *bank*, *job* → *life*).
- **Colapso a frases genéricas.** Hay predicciones que se repiten para entradas distintas: «im so nervous» aparece 11 veces en el test, y 12 frases se tradujeron como vacías: el primer token predicho fue [end], casi siempre con entradas de una o dos palabras (*mañana*, *cemento*, *nombre*). Una posible explicación: con decodificación voraz, cuando la entrada aporta poca evidencia, el decodificador sigue la secuencia más probable según su modelo de lenguaje en inglés; en entrenamiento hay 20 frases con *so nervous* (todas de la clase Anxiety). Es una hipótesis: no se verificó con otra estrategia de decodificación.
- **BLEU frente a ROUGE/F1.** En ROUGE-1, ROUGE-L y F1 el modelo duplica a la línea base de copiar el español (ROUGE-1 21,9 frente a 10,2; F1 21,8 frente a 10,5; en ROUGE-2 la ventaja es menor: 5,7 frente a 3,2), pero en BLEU queda prácticamente igual o por debajo (3,32 frente a 3,47). La copia acierta 4-gramas completos con nombres de usuario, URLs y nombres propios que el traductor del dataset dejó igual (los 4-gramas que acierta la copia son cosas como *http plurk com p* o cadenas de usuarios de Twitter), y el modelo los pierde porque están fuera de su vocabulario. BLEU castiga mucho no tener 4-gramas correctos; por eso para un sistema tan débil ROUGE-1 y F1 distinguen mejor que BLEU.
- **La longitud importa.** BLEU baja de 6,4 en frases de 1–5 palabras a 1,7 en 16–20; F1 va de 23,1 a 18,4 (ROUGE-1 y F1 son casi iguales en 1–5 y 6–10 palabras y caen desde 11). Es consistente con el cuello de botella de un seq2seq sin atención, donde toda la frase pasa por un único vector de estado, aunque aquí no se probó un modelo con atención para confirmarlo.
- **Sobreajuste temprano.** Con 9.758 pares y vocabularios de 13.495 y 11.987 palabras, el 77 % de las palabras distintas aparece una o dos veces en entrenamiento (en ambos idiomas); el modelo, de 30,6 millones de parámetros, memoriza desde la época 5.
- **Calidad del dataset.** La referencia (inglés) es el texto original; lo traducido es la entrada en español. Además de los pares sin traducir que se quitaron, en los textos largos del archivo el español tiene bastantes menos palabras que el inglés, lo que sugiere recortes en la traducción; en las frases cortas que se usaron la proporción es cercana a 1, así que el efecto aquí es menor (mediana es/en = 1,0). La entrada es lenguaje informal de redes (errores, jerga, nombres de usuario), a diferencia de las frases de manual del corpus spa-eng del notebook.
- **Solapamiento entre particiones.** La deduplicación es por par (español, inglés): 27 frases en español del test (1,3 %) también están en entrenamiento con otra traducción, y 37 referencias en inglés (1,8 %). Es poco y no cambia las conclusiones, pero una versión más estricta deduplicaría por la frase en español antes de particionar.

3. Conclusiones y limitaciones

- **Generación:** con un GRU de 512 unidades y un solo libro se obtiene un modelo que imita la superficie del texto (perplejidad 4,16 por carácter en validación), pero no su sentido. La estrategia de decodificación importa tanto como el modelo: argmax, la del notebook, produce ciclos; T = 0,5 da texto legible pero en parte copiado del libro (15,5 % de 5-gramas literales); T ≥ 0,8 es texto propio pero con muchas palabras inventadas. Con un libro de ~170 mil caracteres no hay un punto que lo resuelva todo.
- **Traducción:** el seq2seq GRU sin atención, con ~10 mil pares cortos y ruidosos, logra BLEU 3,32, ROUGE-L 21,1 y F1 21,8. Es un resultado bajo: traduce bien solo frases cortas y frecuentes. Si solo se hubiera reportado BLEU, parecería que no aprendió nada (no le gana a copiar el español); si solo ROUGE-1, que es el doble de bueno que la copia. Las dos lecturas son parciales.
- **Limitaciones:** entrenamiento en CPU (GRU de 512 en lugar de 1024 en el modelo de caracteres), una sola semilla por modelo (no se estima la variabilidad entre corridas), decodificación voraz, métricas sobre texto en minúsculas y sin puntuación, una entrada en español traducida (no escrita por hablantes nativos) y un pequeño solapamiento de frases entre particiones.

- **Siguientes pasos, cada uno por un problema medido:** atención o el Transformer de la siguiente sección del capítulo, por la caída con la longitud (BLEU 6,4 → 1,7); búsqueda en haz, por las 12 salidas vacías y las frases genéricas repetidas; subpalabras (BPE), porque el 9,7 % de las palabras del test no está en el vocabulario y el 77 % del vocabulario aparece una o dos veces; y en generación, más texto del mismo autor, porque el modelo copia frases enteras con T = 0,5.

4. Reproducibilidad

Repositorio: https://github.com/davidm094/NLP_JAVE_TALLER06_202601. `notebooks/Taller06_Generacion_y_Traduccion.ipynb` está listo para Colab (clona el repositorio e instala `sacrebleu` y `rouge-score`); con `ENTRENAR = True` reentrena ambos modelos. Los resultados de este reporte salen de `python src/correr_traduccion.py 1024 15` y `python src/correr_generacion.py 512 60` (más `python src/evaluar_generacion.py` para la tabla de calidad del texto; requiere la copia propia del libro en `data/`) (semilla 42; TensorFlow 2.21, Keras 3.15, CPU), guardados en `results/`. El PDF se regenera con `python src/reporte.py`.